

用于可扩展无线电资源管理的图神经网络

摘要

在无线通信网络中，资源管理问题是通信系统至关重要的一部分，它将严重影响到用户的使用体验。近年来，随着深度学习的快速进步，无线电资源管理问题也从多个角度应用到了深度学习，但是这些方法大多都具有泛化性差，可扩展性差以及可解释性差的问题。为了解决这些问题，本文提出了一种将无线电资源管理问题的自身结构和性质与深度学习方法良好融合的消息传递图神经网络。在深度学习各种方法的思想启发下，无线电资源管理的问题就可以被建模为一个在有向图中的优化问题，同时具备了便于泛化与扩展的性质。最终实验结果表明，本文该方法在不同的规模上确实达到了客观的可扩展性，在满足硬件需求的情况下，问题的计算效率受到问题规模变化的影响并不明显。

关键词：无线电资源管理；神经网络；图神经网络；置换等变性；无线网络建模

1 引言

无线电资源管理（Radio Resource Management, RRM）是无线通信系统中至关重要的组成部分，其是为了在对无线电频谱、信道、功率等资源进行有效的分配和控制，以实现高效且可靠的通信服务。无线电资源管理的核心内容包括频谱管理、信道分配、功率控制、用户接入管理、质量服务（QoS）管理以及负载均衡等多个方面。其中，在功率控制方面，RRM通过调整发射功率来优化信号质量，减少干扰，同时管理接收灵敏度，以确保接收设备在不同环境条件下的有效接收。束波形成（Beamforming）则是作为一种先进的信号处理技术，成为RRM的重要组成部分。束波形成通过调整多个天线的相位和幅度，能够增强特定方向的信号，同时抑制其他方向的干扰，从而提高信号的质量和系统的容量。常见的应用场景包括移动通信网络，无线传感器和卫星通信。

然而无线通信领域的情况随着各种技术发展变得越来越复杂，无线电资源管理的复杂性源于频谱有限性、干扰管理、用户移动性和环境变化的影响、多种技术的共存、用户需求的多样性，以及安全性问题等因素。这些因素相互作用，使得有效管理无线电资源变得尤为挑战。根据当前的相关技术，对于无线电资源管理所研究的方法中存在随着问题规模的扩大，可扩展性的表现较差，同时泛化性差以及由于使用基于深度学习的方法，缺少可解释性的问题。

本方法通过对无线通信进行图建模，将无线通信及无线电资源管理的结构和性质与所使用的神经网络结合，构成图神经网络。这一创新旨在解决当前技术在可扩展性、泛化性和可解释性方面存在的不足，从而使其能够应用于更复杂的无线通信资源管理问题。通过建模，使得图神经网络能够有效捕捉无线通信中节点（如基站、用户设备）之间的关系和交互，利

用图结构来表示不同资源的分布和需求。通过这种方式，模型能够更好地理解和预测网络中的动态变化，提升资源分配的效率，以实现问题规模的变化不会影响无线电资源管理的效率。

2 相关工作

随着近年来深度学习技术的快速发展，许多领域受益于深度学习的方法而获得显著成果，尤其是计算机视觉和自然语言处理的领域。深度学习的发展同时为无线电资源管理带来了更高的效率、更优的资源配置和更好的用户体验，使得无线通信网络在日益复杂的环境中能够更好地应对挑战。随着技术的不断进步，这些好处将会进一步显现，推动无线电资源管理向更智能化的方向发展。研究人员们在无线通信领域对深度学习方法的应用最开始是直接

直接将深度学习应用于无线通信中的相关问题，这样的方法只能加速计算过程，在其他性能方面的表现并不能得到很好的提升。再到后来将无线通信领域中问题的本身结构和性质与深度学习的方法充分融合，提升了在解决问题中的表现，但针对更复杂和规模更大的无线电资源管理的问题中仍然存在需要优化的性能问题，特别体现在可扩展性和泛化性的表现上。

2.1 直接基于深度学习的方法

在无线通信资源管理中，深度学习的应用正逐渐成为研究的热点。像这样直接基于深度学习的方法主要可以分为两种形式，一种是端到端学习，另一种则是边学习边优化。[\[1\]](#)

端到端学习的核心思想是通过神经网络直接映射输入到输出，旨在找到问题的最优解。这种方法的优势在于其高效性，能够快速处理复杂的优化问题，尤其是在大规模数据场景中。此外，端到端学习还减少了对手动特征工程的需求，网络能够自动提取有用特征。然而，它也存在一些劣势，例如对大量标注数据的需求，数据不足时可能导致过拟合，以及深度学习模型通常被视为“黑箱”，其决策过程难以解释。端到端学习方法的示意图如下[1](#)。

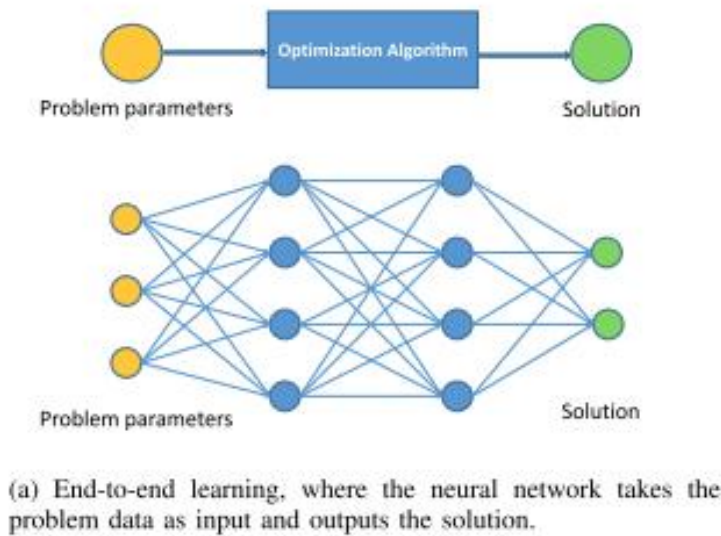


图 1. 端到端学习方法的示意图 [\[1\]](#)

另一方面，边学习边优化的方法则是在传统优化算法中结合深度学习的技术，利用神经

网络来改进传统算法的效率。例如，在分支界限法中，神经网络可以用来优化剪枝策略，从而加速搜索过程。这种方法的优势在于其灵活性，能够结合传统算法的优点，提升整体性能，同时相较于纯深度学习方法，其决策过程更容易理解，具备一定的可解释性。然而，边学习边优化也面临着复杂性的问题，需要设计合理的网络结构和训练策略，增加了系统的复杂性，同时调试和优化的过程也变得更加困难。边学习边优化的示意图如下²。




图 2. 边学习变优化方法的示意图 [1]

以上直接基于深度学习技术端到端和边学习边优化的方法在无线通信中的应用带来了性能上的显著提升，比如在接入点的选择问题上，与传统算法相比，加快了解决问题的计算速度和准确率。在无线通信中，深度学习技术的应用不仅提升了接入点的选择效率，还在多个方面展现了其优势。首先，深度学习模型能够实时分析和适应网络环境的变化，例如用户的移动性和信号强度波动。这使得系统能够在不同的情况下动态调整接入点的选择策略，从而提高了用户体验。其次，通过利用历史数据和实时数据，深度学习模型可以识别出影响网络性能的关键因素。这种数据驱动的决策方式相比传统算法更加智能，能够在复杂的网络中做出更优的选择。此外，深度学习的并行处理能力使得在大规模用户接入时，系统能够迅速处理大量的请求，这种高效的计算能力减少了延迟，提高了网络的整体吞吐量。深度学习模型还具备多任务学习的能力，可以同时处理多个任务，例如信道估计、干扰管理和资源分配等。这种多任务学习的能力使得系统能够更好地协调各个方面的需求，从而优化整体性能。然而在提升解决问题的计算能力以外，这样直接应用深度学习的方法在大规模问题中仍然存在不足之处。因为无法利用无线网络结构，因此在现实中存在的大规模无线资源管理问题中表现出较差的可扩展性和泛化性。

2.2 将无线电资源管理的本质与神经网络结合的方法

在上一模块的方法讨论中，足以证实结合深度学习的方法能够在无线通信的任务中获得更好的计算性能，但是这样将无线通信中的任务视作一个优化问题，然后直接将深度学习的方法应用于这样的任务中不能满足更多的无线通信任务，因为无线通信任务具有较高的复杂性，信道的干扰以及用户规模等因素都会影响优化过程的结果。因此随着研究者们不断探索，

逐渐意识到需要将无线通信中需要解决的问题的本身结构以及性质进行建模，然后将深度学习的方法与目标任务的本身特性结合使用才能够更好地解决问题。

在单天线同质代理系统下，在 [2] 中，探索了一种用于静态信道中无线通信调度的方法，该方法使用了空间卷积技术，将用户们的对应坐标在网格中进行坐标建模。在这一方法中，空间卷积的核心在于通过卷积操作对用户坐标进行建模，以提取信道状态信息。用户的坐标被映射到一个二维网格中，每个网格单元代表一个特定的空间位置，如下图所示3。空间卷积技术不仅提高了信道的利用率，还有效地减少了干扰。通过将用户的坐标映射到网格中，系统能够更精准地分析用户之间的相对位置，从而实现更优化的调度策略。这种图像化的信道状态信息为调度算法提供了丰富的输入数据，使得算法能够实时调整资源分配，最大化网络的整体性能。




图 3. 网格表示用户坐标 [2]

但是考虑到实际无线通信中的复杂情况，这样的方法无法适用于衰落信道。静态信道的信道特性在传输过程中保持不变。在这种信道中，信号的传播条件（如路径损耗、干扰等）是稳定的，因此接收信号的强度和质量不会随着时间的变化而显著改变。相对而言，衰落信道中的信号在传输过程中因为受环境因素影响而导致信号强度和质量会发生变化。这种变化可能是由于多径传播、移动用户、天气变化等因素引起的。在衰落信道中，接收信号的强度会随着时间和空间的变化而波动，导致信号的可靠性降低。因此，以上的方法并没有考虑到链路上的影响因素。于是对于衰落信道，提出了一种随机边缘图神经网络的方法 [3], 由于信道矩阵可以被建模为图的邻接矩阵。因此从这个角度来看，该论文开发了一种在这种图上运行的随机边缘图神经网络（REGNN），并证明了当无线网络中的用户数量发生变化时，它会抑制良好的泛化特性。用图的形式表述如下所示4。




图 4. 图的形式表示带干扰通信 [3]

3 本文方法

在上述相关工作的描述中，只是针对单天线系统同质代理结构下不同情况的解决方法。这些方法在所针对的问题上都得到了一定的性能提升。但是在多天线系统或者单天线系统异质代理结构下，信道矩阵不再符合邻接矩阵的形式，因此以上的方法不能解决这样的情况，因此本文基于 [4] 所提出的方法解决在更复杂情况下的无线电资源管理问题，并且实现较好的可扩展性、泛化性。

3.1 本文方法概述

无线通信过程中涉及到用户、基站以及无形的信道，根据此特点，一定范围内的无线网络可以建模为一个有向图，节点表示基站或者用户，有向边就是通信链路。同时考虑到不同链路之间的干扰，如果存在两个不同节点之间一个节点作为发射器，一个节点作为接收器的直接通信或干扰链路，则在发射节点和接收节点之间绘制一条边。受到卷积神经网络的启发，比如在图像中，我们认为一个像素将受到周围像素的影响，这样的思想正好可以应用在干扰链路中。但是由于无线通信中信道的状态无法满足欧几里得距离的定义，因此提出了图神经网络，同时为了结合边的特性，使用消息传递图神经网络——message passing graph neural networks (MPGNNs)。其中最主要部分是一个结合Aggregate和自身信息的函数 $\phi(\cdot)$ 和Aggregate邻点信息的集合函数。

3.2 问题建模

根据概述所提到的关键点，解决无线电资源管理问题首先将无线网络中的通信进行建模。我们将具有一个基站或者移动用户认为是图中的node，将信道视为有向边，将基站和用户的具体参数视为node features，信道相关得参数视为 edge features。因为需要考虑链路的干扰问题，于是具有一个节点矩阵专门存储节点的信息，其中包括了每个节点所处的信道状态，权重以及噪声系数。每个用户的邻接特征如下图5.其中表示了节点j和k之间的信道状态。

$$A_{(j,k,:)} = \begin{cases} 0, & \text{if } \{j, k\} \notin E \\ h_{j,k} & \text{otherwise,} \end{cases}$$

图 5. 用户邻接特征

因此最后所求解的问题就变成了下图所示的形式，也即是获得一个最大加权和，以此指标来完成无线电资源分配问题，其中的结果受限于当前的最大功率

$$\begin{aligned} \underset{\Gamma}{\text{maximize}} \quad & g(\Gamma, Z, A) = \sum_{k=1}^K Z_{(k, N_t+1)} \log_2 (1 + \text{SINR}_k) \\ \text{subject to} \quad & Q(\Gamma, Z, A) = \|v_k\|_2^2 - P_{\max} \leq 0, \forall k, \end{aligned}$$

图 6. 最终优化问题

3.3 更新规则

在所涉及的模型下，使用消息传递图神经网络能够结合边的特征。综合以上信息，在卷积神经网络的启发下，图神经网络中每个点的更新规则主要是与两个部分有关，一个是来自上一层周围节点的聚合信息，另一个是来自上一次自身节点以及上一层周围节点聚合信息相结合后的结果以生成当前节点的信息。其流程可以如下图所示7。




图 7. 更新示意图

4 复现细节

关于所述方法的实现，以束波形成作为例子实现本文所述的方法。首先需要构建一个无线通信布局，由于需要使用所生成的虚拟基站与用户之间的距离，还需要使用欧几里得公式计算距离，并且存储下来。其中涉及到的基本无线通信参数包括了覆盖区域长度、链路数量、天线配置、链路长度限制、信道带宽、载波率、发射功率和天线高度等信息。接下来是生成无线通信的节点和信道的特征，并且保存下来，其中用到一个随机矩阵表示衰落阴影。然后将上述所生成的数据构建成具有干扰链路的无线通信图。最后搭建消息传递机制的图神经网络以实现目标优化问题。

4.1 与已有开源代码对比

在复现过程中，引用了原论文 [4]所提供的开源代码中束波形成部分神经网络的搭建。包括了一个整体神经网络架构，其中包含一个MLP1(三个隐藏层神经元数量分别是 6 倍的天线数量，64，64)和MLP2（三个隐藏层神经元数量分别是 64 加上 4 倍的天线数量，32，2 倍的天线数量），分别实现的是Aggregate和 Combine两个过程。以及一个自定义的具有消息传递机制的卷积层，继承自 MessagePassing，包含MLP1和MPL2。MLP1接收来自相邻节点的特征和边属性，通过 MLP1 处理后返回聚合后的消息。MLP2接收聚合的输出和当前节点特征，通过 MLP2 更新节点特征，并进行归一化处理。

在原论文开源代码的基础上，我探索了选择MLP方法作为两个功能函数的好处，其原因是无线通信中复杂的节点特征和信道相关的特征，采取linear mapping在这样的问题下难以施展拳脚，因此采用两个不同的MLP1和MLP2分别作为聚合部分和结合部分的功能。其次，我重新整理了代码结构，增强了代码的可读性以及更加便于理解。再者，对于布局生成部分，我在原来基础重新实现布局生成的方法，使其得到一定简化,然后将实验结果完成可视化。最

后在原论文的基础上再次验证了其中排列等变性的性质，确保模型对节点排列的无敏感性，这一特性意味着无论输入图中节点的顺序如何变化，模型的输出应该保持不变。

4.2 实验环境搭建

本方法的开发环境位于Windows操作系统下进行开发，使用的集成开发环境是Pycharm，其中使用的解释器版本为python3.9.0。所用的方法是基于Python的torch架构进行网络搭建。所使用到的Python基本工具有scipy.io、numpy、math。最后的实验只在CPU上完成运行。

5 实验结果分析

在最后的实验部分，我只进行了较小规模的实验验证。首先是训练模型，我通过前面的无线通信布局所实现的方法，生成了2000个训练数据进行训练，我的测试数据为100个不同通信布局。由于设备限制，对于链路和用户数量所选取的都是较小规模的计算。链路数量和接受者数量分别为40、80、160、300。最后我的实验结果如下图8所示。该实验结果表明与传统的WMMSE算法相比，在小规模的数据集中和在CPU运行情况下，论文中的方法能够实现规模不变的计算时间。与论文中的结论一致。

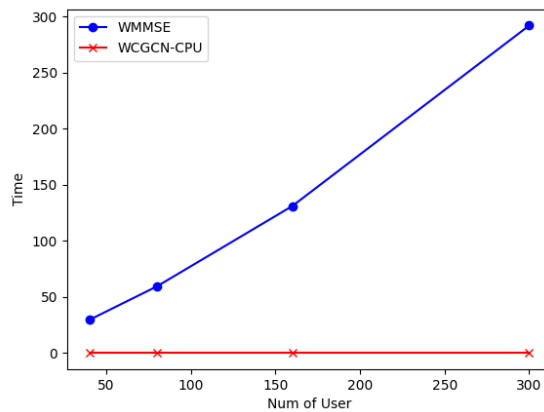


图 8. 小规模实验结果

下图9所示为原论文中的较大规模实验，其用户数量的规模为100到5000。可以看到在其GPU的硬件条件下运行能够实现计算时间的问题规模不变性。




图 9. 原论文实验结果

6 总结与展望

通过发现无线电资源管理问题在当前技术下所存在的可扩展性和泛化性差的问题，以及回顾以往的相关工作逐渐发现更多问题以发现深度学习方法的应用应该与目标问题本身的结构相结合，于是提出了本文中具有消息传递机制的图神经网络。通过对目标问题进行建模然后使用深度学习搭建图神经网络实现了具有较好可扩展性和泛化性的方法。该方法与之前的其他方法相比，其中排列等边行能够使该方法能够更好地训练和泛化。由于网络中的每一个节点都具有聚合与结合功能的数据副本，因此其输入输出维度与问题的规模数量具有不相关性，于是也能够支持更好地泛化到各种规模的问题。由于该方法能够重用数据以及具有更少的参数，比相关的一些方法能够更快地训练。同时，该方法中的两个方法模块中能够并行运行，因此其计算效率能够得到大大提升。本次复现工作也存在不足之处，其中关于无线通信布局的生成不够灵活，并且比较繁琐。在后期的工作中希望能够更加简化这一部分基础工作，同时探索更先进的网络结构加以运用。

参考文献

- [1] Yifei Shen, Yuanming Shi, Jun Zhang, and Khaled B. Letaief. Lorm: Learning to optimize for resource management in wireless networks with few training samples. *IEEE Transactions on Wireless Communications*, 19(1):665–679, 2020.
- [2] Wei Cui, Kaiming Shen, and Wei Yu. Spatial deep learning for wireless scheduling. *ieee journal on selected areas in communications*, 37(6):1248–1261, 2019.
- [3] Mark Eisen and Alejandro Ribeiro. Optimal wireless resource allocation with random edge graph neural networks. *IEEE Transactions on Signal Processing*, 68:2977–2991, 2020.
- [4] Yifei Shen, Yuanming Shi, Jun Zhang, and Khaled B Letaief. Graph neural networks for scalable radio resource management: Architecture design and theoretical analysis. *IEEE Journal on Selected Areas in Communications*, 39(1):101–115, 2020.